Proyecto Final: Predicción del éxito académico en educación superior

Míriam Mingo Revuelta

2º iMAT B

Abstract

Este trabajo analiza el rendimiento académico en educación superior con el objetivo de identificar factores asociados al abandono, la permanencia y el éxito académico. Se abordan tres tareas: clasificación de la situación final del estudiante, regresión para predecir el rendimiento en el segundo semestre y aprendizaje no supervisado para identificar perfiles o estructuras relevantes. Los resultados muestran que el rendimiento en el primer semestre es el principal predictor tanto del desempeño futuro como del abandono. Asimismo, el análisis revela patrones latentes que permiten segmentar a los estudiantes en perfiles diferenciados.

1 Introduction

El abandono académico constituye un problema relevante en educación superior, con implicaciones tanto institucionales como sociales. En este trabajo se aborda desde una perspectiva de modelización de datos, combinando técnicas supervisadas y no supervisadas con el objetivo de obtener no solo modelos predictivos precisos, sino también conclusiones interpretables.

En este contexto, el trabajo se centra en tres tareas: **(i)** la clasificación del estado final del estudiante, **(ii)** la predicción del rendimiento en el segundo semestre y **(iii)** la identificación de perfiles latentes mediante clustering. Este enfoque permite analizar el problema desde distintas perspectivas complementarias.

Las principales contribuciones del trabajo son:

- Análisis comparativo de modelos de clasificación multiclase en presencia de desbalanceo
- Evaluación de modelos de regresión bajo distintos escenarios de información
- Identificación de perfiles de estudiantes mediante aprendizaje no supervisado
- Interpretación de resultados con foco en la toma de decisiones educativas

2 Exploración inicial y análisis descriptivo del conjunto de datos (EDA)

El conjunto de datos incluye variables demográficas, académicas y socioeconómicas, lo que da lugar a un espacio de características que combina variables numéricas y categóricas. Esta diversidad condiciona tanto el preprocesamiento como las decisiones de modelización.

Durante el análisis exploratorio se identificaron varios aspectos relevantes. En primer lugar, la variable objetivo de la tarea de clasificación presenta **desbalanceo**, pues la clase *graduado* es más frecuente que *abandono* y *matriculado*, siendo esta última la menos representada. Este hecho tiene implicaciones directas en la evaluación de modelos, ya que métricas como la *accuracy* pueden resultar engañosas.

Preprint.

En segundo lugar, se observó la existencia de **variables altamente informativas relacionadas con el rendimiento académico**. Aunque esto es positivo desde el punto de vista predictivo, introduce un riesgo de fuga de información (*data leakage*), especialmente en la tarea de regresión. Por este motivo, se adoptaron medidas específicas para evitar este problema.

Estos hallazgos motivan el uso de métricas más robustas (como el F1-score) así como un diseño cuidadoso del proceso de modelización.

3 Preprocesado y decisiones metodológicas

El preprocesamiento constituye una fase clave del análisis, ya que garantiza la validez de los resultados obtenidos.

En primer lugar, las variables categóricas fueron transformadas mediante *one-hot encoding*. Esta decisión incrementa la dimensionalidad del dataset, lo que favorece el uso de modelos capaces de manejar espacios de alta dimensión, como Random Forest o modelos lineales regularizados.

Un aspecto especialmente relevante es el **control de la fuga de información** en la tarea de regresión. Dado que la variable objetivo es la nota media del segundo semestre, se eliminaron todas las variables relacionadas con dicho periodo. De lo contrario, los modelos habrían aprendido relaciones triviales, produciendo resultados irreales en un contexto predictivo.

Adicionalmente, se definieron **dos escenarios experimentales** para la tarea de regresión: uno que excluye cualquier tipo de variable académica y otro que incluye información del primer semestre. Este diseño permite analizar el impacto del rendimiento previo en la predicción del desempeño futuro.

4 Tarea de clasificación

La primera tarea consiste en un problema de clasificación multiclase en el que se pretende **predecir el estado final del estudiante** (abandono, matriculado o graduado).

Dado el desbalanceo entre clases, se empleó el **F1-score** como métrica principal, complementado con accuracy y el análisis del recall en la clase "abandono", pues la detección de estudiantes en riesgo resulta especialmente relevante.

Se evaluaron distintos modelos, incluyendo Random Forest, regresión logística y SVM. Los resultados muestran que Random Forest obtiene el mejor rendimiento global, aunque la regresión logística presenta resultados muy cercanos. Este comportamiento sugiere que la complejidad del problema es moderada y que parte de la estructura de los datos puede ser capturada mediante modelos lineales.

Asimismo, se estimó el mismo modelo de RF en dos configuraciones: una que incluía las variables del segundo semestre y otra que no las incorporaba. Los resultados muestran que la inclusión de estas variables mejora el rendimiento, aunque no drásticamente, lo que sugiere que gran parte de la información predictiva ya está contenida en las variables iniciales.

Modelo	Accuracy	Recall (Abandono)	F1-weighted
Random Forest (RF)	0.7774	0.7711	0.7536
RF (sin variables 2º sem.)	0.7310	0.7112	0.7016
Regresión Logística	0.7548	0.7429	0.7425
SVM	0.7288	0.6584	0.7090

Table 1: Resultados de los modelos de clasificación (Multiclase)

Por otro lado, se observa una **dificultad clara en la predicción de la clase "matriculado"**, que presenta valores inferiores de *recall* y *F1-score*. Este resultado indica la existencia de solapamiento entre clases, probablemente debido a que esta categoría representa una situación intermedia entre abandono y graduado.

Para mitigar el efecto del desbalanceo, se utilizó *class_weight="balanced"*, lo que permitió mejorar el rendimiento en las clases minoritarias a costa de una ligera disminución en la *accuracy*

global. Este comportamiento refleja el *trade-off* entre optimizar la *accuracy* global y mantener un rendimiento homogéneo en todas las clases.

Con el objetivo de evaluar la estabilidad del modelo y evitar que los resultados dependan de una partición concreta de los datos, se aplicó **validación cruzada mediante K-Fold** con 5 particiones. Los resultados obtenidos muestran un F1-score medio de aproximadamente 0.71, con una desviación estándar muy reducida ($\approx$ 0.012), lo que indica una baja variabilidad entre particiones. Este comportamiento sugiere que el modelo presenta una buena capacidad de generalización y que su rendimiento es consistente ante diferentes subconjuntos de entrenamiento y validación.

Adicionalmente, se analizó la **importancia de variables** en el modelo Random Forest. Los resultados muestran que las variables más influyentes corresponden principalmente al rendimiento académico del segundo semestre (número de asignaturas aprobadas y nota media). Este resultado es coherente, pues el rendimiento académico más reciente está estrechamente relacionado con el estado final del estudiante. No obstante, también se observa que variables del primer semestre presentan una relevancia notable, lo que refuerza la idea de que el rendimiento temprano es un factor clave en la trayectoria académica.

Variable	Importancia
Asignaturas aprobadas (2º sem.)	0.3067
Nota media (2º sem.)	0.0984
Asignaturas aprobadas (1er sem.)	0.0392
Asignaturas evaluadas (1er sem.)	0.0360
Matrícula al día (No)	0.0355
Nota de admisión	0.0336
Edad al matricularse	0.0282
Asignaturas evaluadas (2º sem.)	0.0277
Nota media (1er sem.)	0.0267
Nota cualificación previa	0.0258

Table 2: Importancia de las variables en el modelo RF

En conjunto, los resultados indican que **es posible anticipar con un nivel razonable de precisión la situación final del estudiante a partir de la información disponible**, destacando el rendimiento académico de ambos semestres como el principal factor predictivo.

5 Tarea de regresión

La segunda tarea del proyecto consiste en **predecir la nota media del segundo semestre a partir de la información previa disponible del estudiante**, con el objetivo de analizar hasta qué punto es posible anticipar el rendimiento académico futuro.

Para evaluar los modelos se emplearon tres métricas complementarias: **el error absoluto medio (MAE), el error cuadrático medio (RMSE) y el coeficiente de determinación (R^2)**. El MAE mide el error medio en valor absoluto, lo que permite interpretar de forma directa la magnitud típica del error en las predicciones. Por su parte, el RMSE penaliza más los errores grandes, por lo que resulta especialmente sensible a predicciones con desviaciones elevadas. Finalmente, el R^2 mide la proporción de la varianza de la variable objetivo que es explicada por el modelo, permitiendo evaluar su capacidad explicativa global.

Desde el punto de vista metodológico, se definieron dos escenarios:

- **Caso A:** se excluyeron todas las variables relacionadas tanto con el primer como con el segundo semestre, con el objetivo de analizar la capacidad predictiva de variables demográficas y de contexto.
- **Caso B:** se incluyeron las variables del primer semestre, manteniendo la exclusión de las variables del segundo semestre para evitar fuga de información.

Se compararon distintos modelos, incluyendo regresión lineal, Random Forest y regresión regularizada con Ridge.

La regresión lineal presentó un rendimiento muy pobre en ambos escenarios, con valores de R^2 negativos y errores extremadamente elevados. Este comportamiento indica que el modelo no es capaz de capturar la relación entre las variables explicativas y la variable objetivo, lo que sugiere la presencia de relaciones no lineales y posibles problemas derivados de la alta dimensionalidad generada por el *one-hot encoding*.

En contraste, el modelo de Random Forest obtuvo mejores resultados. En el Caso A, sin información académica previa, el modelo alcanza un R^2 aproximado de 0.41, lo que indica una capacidad predictiva moderada basada únicamente en variables de contexto. Sin embargo, al incorporar variables del primer semestre, el rendimiento mejora significativamente, alcanzando valores de R^2 cercanos a 0.74. Este incremento pone de manifiesto que el rendimiento académico previo contiene una gran cantidad de información relevante para predecir el desempeño futuro.

Por su parte, al regularizar con Ridge la regresión lineal anterior se consiguieron alcanzar valores de R^2 en torno a 0.75, comparables e incluso ligeramente superiores a los obtenidos con Random Forest. Este resultado es especialmente relevante, ya que Ridge introduce un término de regularización que penaliza coeficientes excesivamente grandes, lo que permite mitigar problemas de multicolinealidad y sobreajuste en contextos de alta dimensionalidad.

La comparación entre modelos lineales y no lineales sugiere que el problema presenta una **estructura mixta**: aunque existen relaciones no lineales que son capturadas eficazmente por Random Forest, los modelos lineales regularizados también son capaces de aproximar dichas relaciones cuando se controla adecuadamente la complejidad del modelo.

En conjunto, los resultados evidencian una fuerte dependencia temporal en el rendimiento estudiantil. **El desempeño del estudiante en el primer semestre es el predictor más relevante del rendimiento en el segundo semestre**, lo que sugiere que los patrones de comportamiento académico tienden a mantenerse a lo largo del tiempo.

6 Tarea de aprendizaje no supervisado

La tercera tarea del proyecto consiste en **aplicar técnicas de aprendizaje no supervisado con el objetivo de identificar patrones latentes en los datos y descubrir posibles perfiles de estudiantes** sin utilizar la variable objetivo. A diferencia de las tareas anteriores, el interés no es predictivo, sino interpretativo, buscando comprender la estructura interna del dataset.

Para ello, se ha utilizado el algoritmo de **clustering K-Means**. Previamente, fue necesario determinar el número óptimo de clusters. Aunque inicialmente se consideró el *Método del Codo*, la ausencia de un punto de inflexión claramente definido dificultó la elección del valor de K mediante la inercia.

En su lugar, se aplicó el **Método de la Silueta**, que permite evaluar la calidad del agrupamiento midiendo la cohesión y la separación de los clusters. Al analizar el coeficiente de silueta promedio para distintos valores de k, se observó que el valor máximo se alcanza en **K=3**. Además, tras realizar pruebas adicionales con distintos valores de K, se observó que valores superiores no aportaban una mejora significativa, sino que tendían a dividir perfiles ya existentes en grupos muy similares.



Figure 1: Coeficiente de silueta según k (Método de la Silueta)

Asimismo, se analizó la **estabilidad de los clusters obtenidos** frente a diferentes inicializaciones del algoritmo. Para ello, se entrenaron modelos con distintas semillas aleatorias y se compararon las medias de variables clave como la nota media del primer semestre. Los resultados muestran que los perfiles obtenidos son prácticamente idénticos en todos los casos, lo que indica que los clusters identificados son robustos y no dependen del azar.

El análisis de los clusters permite identificar **tres perfiles diferenciados de estudiantes**:

- **Cluster 1:** estudiantes con bajo rendimiento en el primer semestre, caracterizados por un menor número de asignaturas superadas y bajas calificaciones medias. Este grupo concentra la mayor proporción de abandono, lo que indica que el rendimiento inicial es un factor de riesgo relevante.
- **Cluster 2:** estudiantes de mayor edad con buen rendimiento académico. Este perfil sugiere la posible influencia de trayectorias educativas no tradicionales y de factores como la experiencia previa o la motivación.
- **Cluster 3:** estudiantes jóvenes con alto rendimiento, caracterizados por altas calificaciones y un elevado número de asignaturas superadas, asociados a una mayor probabilidad de éxito académico.

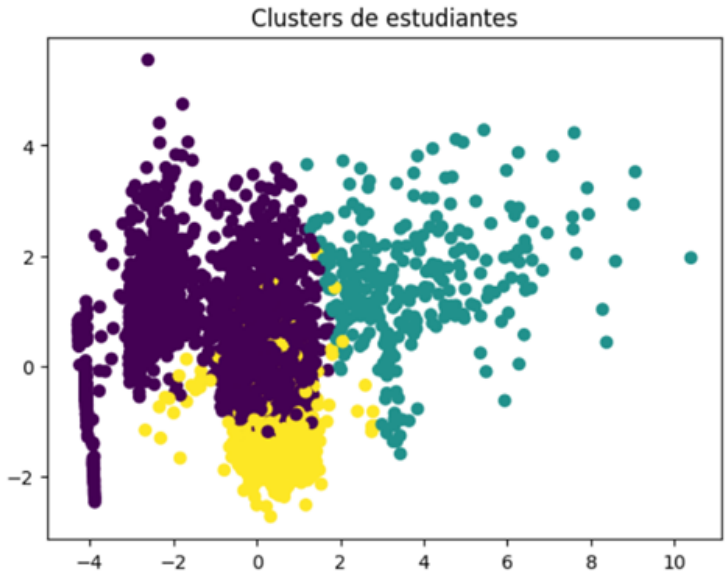


Figure 2: Visualización de clusters mediante PCA

El análisis de las variables que más contribuyen a la separación entre clusters muestra que las más relevantes son la **edad del estudiante** y, especialmente, las **variables de rendimiento académico**, como la nota media o el número de asignaturas aprobadas. En contraste, variables macroeconómicas como el PIB, la inflación o la tasa de desempleo no presentan diferencias significativas entre clusters, lo que sugiere que el rendimiento académico está más asociado a factores individuales que al contexto económico global.

Finalmente, al analizar la **relación entre los clusters y la variable objetivo**, se observa una fuerte correspondencia entre ambos, a pesar de no haber utilizado dicha variable en el proceso de clustering. En particular, el cluster de bajo rendimiento concentra una mayor proporción de abandono, mientras que los clusters de alto rendimiento presentan una mayor proporción de estudiantes graduados. Este resultado indica la existencia de estructura latente en los datos y refuerza la idea de que es posible identificar perfiles de riesgo de forma no supervisada.

En conjunto, este análisis permite concluir que **la población estudiantil no es homogénea, sino que se estructura en perfiles claramente diferenciados**, donde el rendimiento académico inicial y la edad del estudiante son factores clave en la trayectoria académica.

7 Interpretación de los resultados

Los resultados obtenidos permiten responder a las cuestiones planteadas en el estudio. En primer lugar, **el rendimiento académico temprano destaca como el principal factor asociado al abandono**. Además, variables como la nota media y el número de asignaturas aprobadas aparecen de forma consistente como las más relevantes, tanto en los modelos de clasificación como en el análisis de clusters, donde el grupo de bajo rendimiento concentra una mayor proporción de estudiantes que abandonan.

En segundo lugar, **el rendimiento en el segundo semestre presenta una fuerte dependencia del desempeño previo**. La inclusión de variables del primer semestre en la tarea de regresión mejora significativamente la capacidad predictiva del modelo ($R^2 \approx 0.75$), lo que indica que los patrones académicos tienden a mantenerse en el tiempo.

Asimismo, el análisis no supervisado revela la **existencia de perfiles diferenciados de estudiantes**: un grupo de bajo rendimiento con alto riesgo de abandono, un grupo de estudiantes de mayor edad con buen rendimiento y un grupo de estudiantes jóvenes con alto rendimiento académico. Estos resultados confirman que la población estudiantil no es homogénea.

A nivel práctico, los resultados sugieren que podría ser útil implementar estrategias de intervención temprana basadas en el rendimiento del primer semestre, así como diseñar medidas específicas adaptadas a distintos perfiles de estudiantes.

Por otro lado, la comparación entre modelos lineales y no lineales muestra que, aunque los modelos no lineales capturan mejor la complejidad de los datos, los modelos lineales regularizados también ofrecen un buen rendimiento. Asimismo, el análisis del desbalanceo de clases pone de manifiesto la necesidad de equilibrar el rendimiento global con la capacidad de detectar clases minoritarias.

Finalmente, es importante destacar que los resultados reflejan asociaciones estadísticas y no relaciones causales, por lo que deben interpretarse con cautela.

8 Conclusiones y posibles limitaciones

En este trabajo se ha abordado el análisis del rendimiento académico del alumnado mediante técnicas de aprendizaje supervisado y no supervisado. Los resultados obtenidos reflejan la importancia del rendimiento en el primer semestre como principal indicador de la trayectoria académica del estudiante, así como la existencia de perfiles diferenciados dentro de la población estudiantil. Esto sugiere que **es posible anticipar con un nivel razonable de fiabilidad tanto el abandono como el éxito académico** y que la identificación temprana de estudiantes en riesgo puede ser clave para el diseño de estrategias de intervención eficaces.

No obstante, el estudio presenta diversas limitaciones:

- **Limitación 1:** Los resultados se basan en relaciones estadísticas, por lo que no permiten establecer causalidad.
- **Limitación 2:** El desbalanceo de clases puede afectar al rendimiento de los modelos, especialmente en categorías minoritarias.
- **Limitación 3:** El análisis de clustering depende de decisiones como la selección de variables o el número de clusters, lo que introduce cierto grado de subjetividad.

Sin embargo, a pesar de estas limitaciones, el trabajo proporciona una base sólida para comprender los factores asociados al rendimiento académico y constituye un punto de partida útil para futuras investigaciones y aplicaciones en el ámbito educativo.

References

[1] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

[2] Apuntes y diapositivas de la asignatura de Machine Learning. (2026). Universidad Pontificia Comillas.